

Arquitetura e Planejamento de Projeto de Machine Learning

Projeto: Talent Matching AI (Triagem Inteligente de Perfis do LinkedIn)

Autor: Nicolas Bernardo G. de Souza | MBA FGV: Inteligência Artificial & Analytics | Data: Agosto/2026

1. Visão Geral do Problema e Objetivo

O Problema: Em processos seletivos com dezenas ou centenas de candidatos por vaga, a triagem manual de currículos e perfis do LinkedIn consome tempo excessivo das equipes de RH (média de 30 a 40 horas por vaga). Além disso, a análise sob pressão de tempo gera inconsistência, fadiga e viés inconsciente, resultando na perda de bons talentos ou avanço de candidatos com baixo alinhamento.

Objetivo da IA: Prever um **Score de Match (0% a 100%)** de aderência técnica e comportamental entre o perfil do candidato (LinkedIn em PDF/texto) e os requisitos específicos da vaga alvo.

Métricas de Sucesso (Negócio):

- Redução de **65% no tempo médio de triagem** inicial de candidatos.
- Aumento de **15% na taxa de aprovação** dos candidatos encaminhados para a fase de entrevista com os gestores ($\text{Precision@5} \geq 80\%$).

2. Coleta e Preparação de Dados

Fontes de Dados: Perfis do LinkedIn (exportados em PDF ou texto bruto de resumo, histórico de cargos, competências e formação) e descrições textuais das vagas (requisitos obrigatórios, desejáveis, senioridade e desafios da área).

Qualidade dos Dados:

- Sanitização de texto em Python (remoção de caracteres especiais e formatações espúrias).
- Tratamento de valores nulos e caixas vazias com preenchimento padrão padronizado.
- Limpeza de outliers e restrição de limites (clipping de anos de experiência entre 0.5 e 30.0 anos).

Engenharia de Features: Vetorização N-Gram (TF-IDF 1-2 n-grams) para captura de termos compostos ('power bi', 'analytics engineer'), extração automática de senioridade acumulada via Regex e padronização vetorial via *StandardScaler*.

3. Estratégia de Bases e Separação de Dados

Armazenamento: Dados processados e vetorizados mantidos em DataFrames *pandas* em memória. No ambiente de produção, dados de treinamento e logs são persistidos localmente em formato Parquet/SQL.

Metodologia de Split: Divisão estratificada de **70% para Treinamento** (420 amostras) e **30% para Teste** (180 amostras), garantindo reprodutibilidade com semente fixa (`random_state=42`).

Prevenção de Vazamento (Data Leakage): Os transformadores (*TfidfVectorizer* e *StandardScaler*) executam o método `.fit()` **estritamente sobre os dados de treino**. Os dados de teste e os novos PDFs recebidos no app aplicam apenas `.transform()`, impedindo qualquer contaminação das estatísticas de teste no modelo.

4. Seleção de Algoritmos

Modelo Baseline: Modelo estatístico direto baseado em TF-IDF + Similaridade de Cosseno + Regra de Ponderação de Experiência.

Modelo Avançado (Candidato): Rede Neural do tipo **MLPRegressor** (Multi-Layer Perceptron) com 2 camadas ocultas (32 e 16 neurônios) e função de ativação ReLU.

Justificativa: O modelo Baseline é rígido e exige correspondência de palavras exatas. O *MLPRegressor* aprende combinações não lineares entre termos técnicos e tempo de carreira, entendendo que anos de experiência sólida em dados compensam pequenas variações de nomenclatura.

5. Estratégia de Treinamento e Otimização

Função de Custo (Loss Function): Erro Quadrático Médio (**MSE - Mean Squared Error**), minimizado pelo otimizador estocástico **Adam**.

Otimização de Hiperparâmetros: Configuração de regularização L2 ($\alpha=0.01$) e mecanismo de parada precoce (`early_stopping=True` com `n_iter_no_change=15`), interrompendo o treinamento automaticamente caso o erro de validação pare de cair.

6. Testes, Validação e Métricas

Métricas de Avaliação Técnica: Erro Médio Absoluto (**MAE = 4.14%**), Raiz do Erro Quadrático Médio (**RMSE = 5.47%**) e Correlação de Ranking de Spearman ($\rho = 0.985$).

Impacto e Matriz de Decisão: Falsos Positivos geram entrevistas desnecessárias; Falsos Negativos perdem bons talentos. O modelo prioriza alto Recall no Top 5 (`Precision@5`).

Testes de Viés e Generalização: Execução de **Validação Multi-seed (seeds 42, 7 e 123)**. O modelo manteve estabilidade (MAE médio de $4.2\% \pm 0.3\%$), comprovando que não há overfitting nem sorte por amostragem.

7. MLOps: Deploy e Monitoramento

Estratégia de Implantação: Web App interativo desenvolvido em **Streamlit** (`app.py`), permitindo consumo em tempo real por recrutadores sem necessidade de conhecimento em programação.

Monitoramento Contínuo:

- **Data Drift:** Monitoramento das palavras-chave mais frequentes nos novos currículos para atualizar o vocabulário TF-IDF periodicamente.
- **Concept Drift:** Acompanhamento contínuo da taxa de aprovação dos candidatos pré-selecionados pela IA nas entrevistas finais com os gestores.